

EL MODELO LINEAL

Clase 3

Regresión múltiple

Sergio Camiz

LIMA - Marzo-Mayo 2025

10/04/2025 "Clase_3 - regresion multiple" III - 1/42

Clase 3 Notación matricial

Notación matricial

Si tenemos dos vectores, $\mathbf{y} = (y_1, \dots, y_n)'$ respuesta y $\mathbf{x} = (x_1, \dots, x_n)'$ explicativo, se puede expresar toda la teoría del modelo lineal en forma matricial, si juntamos un tercer vector $\mathbf{1} = (1, \dots, 1)'$ y, en lugar de $(\alpha, \beta)'$, consideramos el vector de parámetros $\boldsymbol{\beta} = (\beta_1, \beta_2)'$. Ahora se puede construir la matriz de regresores $\mathbf{X} = (\mathbf{1}, \mathbf{x})$ así que el modelo lineal se escribe

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$$

con $\boldsymbol{\varepsilon} = (e_1, \dots, e_n)'$ vector de residuos.

Con esta notación el modelo lineal consiste en estimar $\hat{\boldsymbol{\beta}}$ de manera que

$$SS_e(\hat{\boldsymbol{\beta}}) = \min_{\boldsymbol{\beta}} \|\mathbf{y} - \mathbf{X}\boldsymbol{\beta}\|^2 = \min_{\boldsymbol{\beta}} (\mathbf{y} - \mathbf{X}\boldsymbol{\beta})'(\mathbf{y} - \mathbf{X}\boldsymbol{\beta})$$

10/04/2025 "Clase_3 - regresion multiple" III - 3/42

Asuntos de la clase 3

- Notación matricial
- La regresión lineal múltiple
- Estimación de los parámetros
- Análisis de la varianza
- Apalancamiento

10/04/2025 "Clase_3 - regresion multiple" III - 2/42

Clase 3 Notación matricial

Derivando parcialmente y igualando a cero, se consigue el sistema de ecuaciones:

$$\frac{\partial SS_e(\boldsymbol{\beta})}{\partial \boldsymbol{\beta}} = -2\mathbf{X}'(\mathbf{y} - \mathbf{X}\boldsymbol{\beta}) = 0$$

donde $\mathbf{X}'\mathbf{X}\boldsymbol{\beta} = \mathbf{X}'\mathbf{y}$, así que

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}$$

y

$$\hat{\boldsymbol{\eta}} = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}.$$

La condición de mínimo se resulta ya que

$$\frac{\partial^2 SS_e(\boldsymbol{\beta})}{\partial \boldsymbol{\beta}^2} = 2\mathbf{X}'\mathbf{X} \geq 0$$

10/04/2025 "Clase_3 - regresion multiple" III - 4/42

Efectivamente en el caso que $\mathbf{X} = (\mathbf{1}, \mathbf{x})$ se resulta:

$$\mathbf{X}'\mathbf{X} = \begin{pmatrix} n & S_x \\ S_x & S_{xx} \end{pmatrix} \quad \text{y} \quad (\mathbf{X}'\mathbf{X})^{-1} = \begin{pmatrix} \frac{S_{xx}}{nS_{xx}-S_x^2} & \frac{-S_x}{nS_{xx}-S_x^2} \\ \frac{-S_x}{nS_{xx}-S_x^2} & \frac{n}{nS_{xx}-S_x^2} \end{pmatrix}.$$

Además $\mathbf{X}'\mathbf{y} = \begin{pmatrix} S_y \\ S_{xy} \end{pmatrix}$, así que

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y} = \begin{pmatrix} \frac{S_y S_{xx} - S_x S_{xy}}{nS_{xx} - S_x^2} \\ \frac{nS_{xy} - S_x S_y}{nS_{xx} - S_x^2} \end{pmatrix} \quad \text{y} \quad \hat{\boldsymbol{\eta}} = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}.$$

Se reconoce que $\hat{\beta}_2 = \frac{nS_{xy} - S_x S_y}{nS_{xx} - S_x^2} = \frac{S_{\bar{x}\bar{y}}}{S_{\bar{x}\bar{x}}} = \hat{\beta}$, y sustituyendo esto en α se resulta $\hat{\alpha} = \bar{y} - \hat{\beta}_2 \bar{x} = \frac{S_y}{n} - \frac{nS_{xy} - S_x S_y}{nS_{xx} - S_x^2} \frac{S_x}{n} = \frac{(S_y S_{xx} - S_x S_{xy}) - (S_x S_{xy} - S_y S_x^2/n)}{nS_{xx} - S_x^2} = \frac{S_y S_{xx} - S_x S_{xy}}{nS_{xx} - S_x^2} = \hat{\beta}_1$.

10/04/2025


"Clase_3 - regresion multiple"

III - 5/42

Clase 3

La regresión lineal múltiple

Con dos variables explicativas hay un plan de regresión en \mathbb{R}^3 .



10/04/2025

"Clase_3 - regresion multiple"

III - 7/42

La regresión lineal múltiple

La notación matricial permite de generalizar los resultados conseguidos al caso de un conjunto de variables explicativas.

El *modelo de regresión lineal múltiple* es un modelo en el cual los parámetros aparecen linealmente en la ecuación, que se vuelve

$$\boldsymbol{\eta} = \sum_{j=1}^p \beta_j \mathbf{x}_j = \mathbf{X}\boldsymbol{\beta}$$

donde las componentes \mathbf{x}_j de \mathbf{X} solo son función de variables \mathbf{z}_h sin parámetros a estimar.

Desde aquí hacia adelante, siempre se supone que entre las p variables explicativas, haya una compuesta para una columna de 1, que sirve para estimar el α , así que hablando de p columnas se estará entendiendo $p - 1$ regresores más la estimación de α .

10/04/2025


"Clase_3 - regresion multiple"

III - 6/42

Clase 3

La regresión lineal múltiple

El caso $\mathbf{y} = \boldsymbol{\beta}(\mathbf{1}, \mathbf{x})$ se puede ver como la intersección del plano de regresión con el plano vertical $x_1 = 1$, o sea una recta.



10/04/2025

"Clase_3 - regresion multiple"

III - 8/42

Modelo geométrico

- Se hicieron n observaciones, con $n \gg p$, del carácter respuesta y_i , $i \in (1, n)$ correspondiendo a valores prefijos de variables descriptivas x_{i1}, \dots, x_{ip} , $i \in (1, n)$.
- Se quiere estimar los parámetros del modelo lineal con y variable respuesta y p descriptivas (x_1, \dots, x_p) .
- Normalmente se supone que el primero sea el vector constante $x_1 = \mathbf{1}$, que sirve para estimar la constante del modelo, resultando la matriz $\mathbf{X}_{n \times p}$.
- Cada variable y y x_j (columnas de \mathbf{X}) son vectores con n componentes, así que son vectores en el espacio \mathbb{R}^n .
- Los residuos ε_i , $i \in (1, n)$ forman también un vector $\varepsilon \in \mathbb{R}^n$.
- En forma vectorial, el modelo se escribe

$$y = \eta + \varepsilon = \mathbf{X}\beta + \varepsilon$$

10/04/2025

"Clase_3 - regresion multiple"

III - 9/42

Clase 3

La regresión lineal múltiple


- Las p columnas de \mathbf{X} como vectores de \mathbb{R}^n generan un subespacio $X \subset \mathbb{R}^n$, cuya dimensión es a lo más $p < n$.
- A este espacio se lo llama *espacio solución, de regresión u de estimación*.
- Su dimensión es p solo si los regresores son *linealmente independientes* y en este caso se dice que el sistema es *de rango completo*.
- Resulta que $\eta = \mathbf{X}\beta \in X$, es decir que se quiere *estimar el vector y en \mathbb{R}^n para un vector η de X* .
- Por esto se busca, en estas condiciones, *cual es la mejor estimación posible*, o sea cual es el mejor estimador de y para un vector de X , como combinación lineal de vectores-columnas de \mathbf{X} .

10/04/2025

"Clase_3 - regresion multiple"

III - 11/42

La representación de y, x_1, x_2 en \mathbb{R}^n y las proyecciones ortogonales



10/04/2025

"Clase_3 - regresion multiple"

III - 10/42

Clase 3

La regresión lineal múltiple

- Desde el punto de vista geométrico, el espacio \mathbb{R}^n es Euclidiano, o sea con producto escalar entre vectores v y w

$$\langle v, w \rangle = \sum_i v_i w_i,$$

- A dos vectores v, w se llaman *ortogonales* si $\langle v, w \rangle = 0$.
- Se deduce una norma de los vectores o sea su longitud

$$\|v\|^2 = \langle v, v \rangle = \sum_i v_i^2,$$

- una distancia Euclidiana entre puntos dada de la norma del vector que junta los dos puntos. Si O es la origen y P, Q dos puntos, entonces

$$d(P, Q) = \|OP - OQ\|$$

10/04/2025

"Clase_3 - regresion multiple"

III - 12/42

- Dados \mathbf{v}, \mathbf{w} , la *proyección ortogonal* de \mathbf{v} sobre \mathbf{w} es el vector colineal a \mathbf{w}

$$\mathcal{P}_{\mathbf{w}}\mathbf{v} = \frac{\langle \mathbf{v}, \mathbf{w} \rangle}{\|\mathbf{w}\|^2} \mathbf{w}$$

- su *complemento ortogonal*

$$\mathcal{P}_{\perp \mathbf{w}}\mathbf{v} = (I - \mathcal{P}_{\mathbf{w}})\mathbf{v} = \mathbf{v} - \mathcal{P}_{\mathbf{w}}\mathbf{v} = \mathbf{v} - \frac{\langle \mathbf{v}, \mathbf{w} \rangle}{\|\mathbf{w}\|^2} \mathbf{w}$$

- Resultan

$$\mathbf{v} = \mathcal{P}_{\mathbf{w}}\mathbf{v} + \mathcal{P}_{\perp \mathbf{w}}\mathbf{v} \quad \text{y} \quad \langle \mathcal{P}_{\mathbf{w}}\mathbf{v}, \mathcal{P}_{\perp \mathbf{w}}\mathbf{v} \rangle = 0$$

- Nótese que, dado un vector \mathbf{v} y un subespacio S cualquier, siempre existen su proyección ortogonal sobre S y su complemento también.


10/04/2025

"Clase_3 - regresion multiple"

III - 13/42

Clase 3

La regresión lineal múltiple



- En \mathbb{R}^3 por el teorema de Pitágoras la distancia $d(\mathbf{y}, \mathcal{P}(\mathbf{y}))$ es mínima en cuanto $\mathbf{y}\mathbf{y}'$ es la hipotenusa de $\mathbf{y}\mathcal{P}\mathbf{y}'$.
- La solución de mínimos cuadrados se encuentra para la proyección ortogonal de \mathbf{y} sobre el espacio X generado para $(\mathbf{x}_0, \dots, \mathbf{x}_p)$.

10/04/2025

"Clase_3 - regresion multiple"

III - 15/42

- Dado un espacio S , siempre se puede construir una base compuesta por vectores ortogonales.
- Un vector \mathbf{v} es ortogonal a un subespacio S si el es ortogonal a todos los vectores de una base de S .
- por tanto (teorema de Pitágoras)

$$\mathbf{v} = \mathcal{P}_S\mathbf{v} + \mathcal{P}_{\perp S}\mathbf{v} \quad \text{y} \quad \langle \mathcal{P}_S\mathbf{v}, \mathcal{P}_{\perp S}\mathbf{v} \rangle = 0$$

- y la distancia de un punto P a un subespacio S resulta

$$d(P, S) = \|\mathcal{P}_{\perp S}(\mathbf{OP})\| = \min_{s \in S} d(P, s)$$

10/04/2025

"Clase_3 - regresion multiple"

III - 14/42

Clase 3

La regresión lineal múltiple

Teorema. El punto

$$\hat{\boldsymbol{\eta}} = \mathcal{P}_X(\mathbf{y})$$

es el punto de X , subespacio generado para \mathbf{X} más cercano a \mathbf{y} .

- Geométricamente la solución dada para la proyección *siempre existe y es única*.
- Esta se consigue empleando el *operador ortogonal de proyección* sobre X , \mathcal{P}_X .
- Dado cualquier vector \mathbf{y} , el vector $\mathbf{y} - \mathcal{P}_X(\mathbf{y})$, es ortogonal a cada vector de X ,

10/04/2025

"Clase_3 - regresion multiple"

III - 16/42

- entonces cada vector de \mathbb{R}^n se encuentra compartido en dos componentes

$$\mathbf{y} = \mathcal{P}_X \mathbf{y} + (\mathbf{y} - \mathcal{P}_X \mathbf{y})$$

- el espacio también resulta compartido como *suma directa* de sub-espacios ortogonales:
- Si se escribe

$$\mathbf{y} - \mathcal{P}_X \mathbf{y} = (I - \mathcal{P}_X) \mathbf{y} = \mathcal{P}_{X^\perp} \mathbf{y} = \mathcal{E}_X \mathbf{y}$$

resulta por tanto

$$\mathbf{y} = \mathcal{P}_X \mathbf{y} \oplus (\mathbf{y} - \mathcal{P}_X \mathbf{y}) = \mathcal{P}_X \mathbf{y} \oplus \mathcal{E}_X \mathbf{y}.$$

10/04/2025

"Clase_3 - regresion multiple"

III - 17/42

Clase 3

Estimación de los parámetros

Estimación de los parámetros

Utilizando el teorema de Pitágoras, resulta que el mínimo

$$\begin{aligned} SS_e &= \min_{\mathbf{s}} (\mathbf{y} - \mathbf{s})'(\mathbf{y} - \mathbf{s}) \\ &= \min_{\mathbf{s}} ((\mathbf{y} - \hat{\boldsymbol{\eta}})'(\mathbf{y} - \hat{\boldsymbol{\eta}}) + (\hat{\boldsymbol{\eta}} - \mathbf{s})'(\hat{\boldsymbol{\eta}} - \mathbf{s})) = \\ &= \min_{\boldsymbol{\theta}} ((\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}})'(\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}}) + (\mathbf{X}(\hat{\boldsymbol{\beta}} - \boldsymbol{\theta}))'(\mathbf{X}(\hat{\boldsymbol{\beta}} - \boldsymbol{\theta}))) \end{aligned}$$

se consigue cuando el segundo término es cero, o sea cuando

$$\boldsymbol{\theta} = \hat{\boldsymbol{\beta}}$$

Se puede calcular $\hat{\boldsymbol{\beta}}$ considerando que $\mathbf{e} = \mathbf{y} - \hat{\boldsymbol{\eta}} \in X^\perp$, porque así \mathbf{e} es ortogonal a cada vector de X , donde desde

$$\mathbf{X}'\mathbf{e} = \mathbf{X}'(\mathbf{y} - \hat{\boldsymbol{\eta}}) = (\mathbf{X}'\mathbf{y} - \mathbf{X}'\mathbf{X}\hat{\boldsymbol{\beta}}) = \mathbf{0}$$

10/04/2025

"Clase_3 - regresion multiple"

III - 19/42

- el espacio también resulta compartido como *suma directa* de sub-espacios ortogonales: $X \oplus X^\perp$
- Cada proyector ortogonal es *idempotente*, o sea $\mathcal{P} \circ \mathcal{P} = \mathcal{P}$ y por tanto $\mathcal{P} \circ \mathcal{E} = \mathcal{P} \circ (I - \mathcal{P}) = \mathcal{P} - \mathcal{P} \circ \mathcal{P} = \mathbf{0}$.
- En el caso, $\mathbb{R}^n = X \oplus X^\perp$, donde X^\perp es el *complemento ortogonal de X* en \mathbb{R}^n , la proyección ortogonal de \mathbf{y} en X es

$$\mathcal{P}_X \mathbf{y} = \hat{\boldsymbol{\eta}} = \mathbf{X}\hat{\boldsymbol{\beta}},$$

donde resulta $\mathbf{y} = \hat{\boldsymbol{\eta}} + \mathbf{e}$ con $\mathbf{y} - \hat{\boldsymbol{\eta}} = (I - \mathcal{P}_X) \mathbf{y} = \mathbf{e} \in X^\perp$.

- A X^\perp se lo llama el *espacio de los errores* o de los *residuos*.

10/04/2025

"Clase_3 - regresion multiple"

III - 18/42

Clase 3

Estimación de los parámetros

resulta el sistema de *ecuaciones normales*

$$\mathbf{X}'\mathbf{X}\hat{\boldsymbol{\beta}} = \mathbf{X}'\mathbf{y}. \quad (1)$$

La solución (siempre existente) de (1) simplemente sería

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}'\mathbf{y} \quad (2)$$

y por consecuencia

$$\hat{\boldsymbol{\eta}} = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}'\mathbf{y} \quad (3)$$

Para su cálculo, hay que invertir $\mathbf{X}'\mathbf{X}$, solo posible en el caso de rango completo. Si al contrario el rango es $r < p + 1$ se hace recurso a su *inversa generalizada*.

10/04/2025

"Clase_3 - regresion multiple"

III - 20/42

Dada una matriz \mathbf{A} se llama su *inversa generalizada* una matriz \mathbf{A}^g tal que $\mathbf{A}\mathbf{A}^g\mathbf{A} = \mathbf{A}$.

Dada una matriz \mathbf{A} se llama su *inversa de Moore-Penrose* a la matriz \mathbf{A}^+ (única) tal que

1. $\mathbf{A}\mathbf{A}^+\mathbf{A} = \mathbf{A}$.
2. $\mathbf{A}^+\mathbf{A}\mathbf{A}^+ = \mathbf{A}^+$.
3. $(\mathbf{A}\mathbf{A}^+)^t = \mathbf{A}\mathbf{A}^+$.
4. $(\mathbf{A}^+\mathbf{A})^t = \mathbf{A}^+\mathbf{A}$.

Si la descomposición a valores singulares de $\mathbf{A} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^t$, con $\mathbf{U}^t\mathbf{U} = \mathbf{I}$, $\mathbf{V}^t\mathbf{V} = \mathbf{I}$ y $\mathbf{\Sigma}$ diagonal, se resulta $\mathbf{A}^+ = \mathbf{U}\mathbf{\Sigma}^+\mathbf{V}^t$ con $0 \neq \sigma_{ii}^+ = \sigma_{ii}^{-1}$.

Normalmente, los programas de modelos lineales se la utilizan directamente.

10/04/2025

"Clase_3 - regresion multiple"

III - 21/42

Clase 3

Estimación de los parámetros

Del punto de vista geométrico, se ha visto que $\hat{\boldsymbol{\eta}} = \mathcal{P}_X \mathbf{y}$ es la proyección ortogonal de \mathbf{y} sobre el espacio X , generado para los descriptores columnas de \mathbf{X} . Ahora, como tenemos

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}$$

desde (3) tenemos que

$$\hat{\boldsymbol{\eta}} = \mathbf{X}\hat{\boldsymbol{\beta}} = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y} = \mathcal{P}\mathbf{y}.$$

Como $\hat{\boldsymbol{\eta}}$ se encuentra en X , es fácil de averiguar que

$$\mathcal{P} = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'$$

es simétrica y idempotente, y por lo tanto es el proyector ortogonal sobre X , \mathcal{P}_X .

10/04/2025

"Clase_3 - regresion multiple"

III - 23/42

Hay que considerar que la solución geométrica siempre existe, ya que se trata de una proyección.

- Si el rango es completo, $\dim X = p$ y $\hat{\boldsymbol{\beta}}$ se estima sin problema.
- Si el rango no es completo, $\dim X = r < p$, significa que unos de los descriptores son combinación lineal de los demás y hay que tirarlos, sino las coordenadas de los puntos en el espacio resultan indeterminadas, ya que los regresores no son una base del espacio.
- Hay casos donde los programas mismos hacen esta selección automáticamente.

En seguida, consideramos el rango completo, o sea

$$\dim X = \text{rank} \mathbf{X} = p.$$

10/04/2025

"Clase_3 - regresion multiple"

III - 22/42

Clase 3

Estimación de los parámetros

Teorema Una matriz idempotente es un proyector ortogonal si y solo si es simétrica.

Si $\mathbb{R}^n = X \oplus X^\perp$, ortogonales, sean $\mathbf{x}, \mathbf{y} \in \mathbb{R}^n$, entonces, proyectando sobre X , se resulta

$$\langle \mathcal{P}(\mathbf{x}), \mathbf{y} - \mathcal{P}(\mathbf{y}) \rangle = \langle \mathbf{x} - \mathcal{P}(\mathbf{x}), \mathcal{P}(\mathbf{y}) \rangle = 0$$

y por lo tanto

$$\langle \mathcal{P}(\mathbf{x}), \mathbf{y} \rangle = \langle \mathcal{P}(\mathbf{x}), \mathcal{P}(\mathbf{y}) \rangle = \langle \mathbf{x}, \mathcal{P}(\mathbf{y}) \rangle$$

simétrica.

Si al contrario es simétrica, entonces

$$\langle \mathcal{P}(\mathbf{x}), \mathbf{x} - \mathcal{P}(\mathbf{x}) \rangle = \langle \mathcal{P}(\mathbf{x}), \mathbf{x} \rangle - \langle \mathcal{P}(\mathbf{x}), \mathcal{P}(\mathbf{x}) \rangle =$$

$$\langle \mathcal{P}(\mathbf{x}), \mathbf{x} \rangle - \langle \mathcal{P}^2(\mathbf{x}), \mathbf{x} \rangle =$$

$$\langle \mathcal{P}(\mathbf{x}), \mathbf{x} \rangle - \langle \mathcal{P}(\mathbf{x}), \mathbf{x} \rangle = 0,$$

ortogonal.

10/04/2025

"Clase_3 - regresion multiple"

III - 24/42

Por lo tanto, $\mathcal{P}_X = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'$ es el proyector ortogonal sobre X , y como $\hat{\boldsymbol{\eta}}$ se encuentra en X , es la *proyección ortogonal de \mathbf{y} sobre X* , que tiene dimension p .

En consecuencia, el vector $\mathbf{e} = \mathbf{y} - \hat{\boldsymbol{\eta}} = (\mathbf{I} - \mathcal{P}_X)\mathbf{y} = \mathcal{E}\mathbf{y}$ es la proyección ortogonal de \mathbf{y} sobre el espacio de residuos X^\perp que entonces tiene dimensión $n - p$.

En adelante, si no hay confusión, a \mathcal{P}_X se lo escribiremos \mathcal{P} .

10/04/2025

"Clase_3 - regresion multiple"

III - 25/42

Clase 3

Estimación de los parámetros

- $SS_r = \hat{\boldsymbol{\eta}}'\hat{\boldsymbol{\eta}}$ es la norma del vector $\hat{\boldsymbol{\eta}}$, que vale

$$\begin{aligned} SS_r &= \hat{\boldsymbol{\eta}}'\hat{\boldsymbol{\eta}} = \hat{\boldsymbol{\beta}}'\mathbf{X}'\mathbf{X}\hat{\boldsymbol{\beta}} = \\ &= \mathbf{y}'\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y} = \\ &= \mathbf{y}'\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y} = \mathbf{y}'\mathcal{P}\mathbf{y} \end{aligned}$$

y que puede verse también como el producto escalar $\mathbf{y}'\hat{\boldsymbol{\eta}}$;

- $SS_e = \mathbf{e}'\mathbf{e}$ es la norma del vector \mathbf{e} , y resulta

$$SS_e = \mathbf{e}'\mathbf{e} = \mathbf{y}'\mathcal{E}'\mathcal{E}\mathbf{y} = \mathbf{y}'\mathcal{E}\mathbf{y}$$

y que corresponde también a $\mathbf{y}'\mathbf{e}$.

10/04/2025

"Clase_3 - regresion multiple"

III - 27/42

Se consiguen los resultados siguientes:

- $\hat{\boldsymbol{\beta}}$ es el estimador de mínimos cuadrados de $\boldsymbol{\beta}$, que minimiza la distancia entre \mathbf{y} y su estimador colocado en el espacio de los regresores X ;
- $\hat{\boldsymbol{\eta}}$ *proyección ortogonal de \mathbf{y} sobre X* es el vector de los *valores ajustados* para la regresión: como proyección ortogonal de \mathbf{y} sobre X , es el punto de X más cercano de \mathbf{y} ;
- \mathbf{e} *proyección ortogonal de \mathbf{y} sobre X^\perp* es el vector de los *residuos*, ortogonal a $\hat{\boldsymbol{\eta}}$;

10/04/2025

"Clase_3 - regresion multiple"

III - 26/42

Clase 3

Estimación de los parámetros

- como \mathcal{P} y \mathcal{E} son simétricos e idempotentes, resultan

$$\begin{aligned} r(\mathcal{P}) &= \text{tr}(\mathcal{P}) = \text{tr}(\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}') = \\ &= \text{tr}(\mathbf{X}'\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}) = \text{tr}(\mathbf{I}_{p+1}) = p \\ r(\mathcal{E}) &= \text{tr}(\mathcal{E}) = \text{tr}(\mathbf{I}_n - \mathcal{P}) = \text{tr}(\mathbf{I}_n) - \text{tr}(\mathcal{P}) = n - p \end{aligned}$$

10/04/2025

"Clase_3 - regresion multiple"

III - 28/42

Análisis de la varianza

Cuando un modelo se estima a través de los mínimos cuadrados, se pueden descomponer las sumas de los cuadrados de los valores observados en una parte, correspondiente a la suma de los cuadrados de los valores estimados más la parte correspondiente al desvío de los valores observados a los valores estimados.

1. Las n observaciones son repartidas en q clases con numerosidad $n_1 + n_2 + \dots + n_q = n$.

En este caso, se supone que el modelo consiste en el afectar a cada grupo el promedio de su observaciones.

$$SS_T = \sum_{i=1}^n y_i^2 = \sum_{k=1}^q n_k \bar{y}_k^2 + \sum_{k=1}^q \sum_{i=1}^{n_k} (y_{ik} - \bar{y}_k)^2 = SS_B + SS_W$$

10/04/2025 "Clase_3 - regresion multiple" III - 29/42

Clase 3 Análisis de la varianza

2. Las n observaciones tienen que ser estimadas con un modelo lineal simple y se calcula la suma de cuadrados del desvío al modelo, o sea los residuos:

$$\begin{aligned} SS_e &= \sum_i (y_i - \hat{\eta}_{x_i})^2 = \sum_i (y_i - \hat{\alpha} - \hat{\beta}x_i)(y_i - \hat{\alpha} - \hat{\beta}x_i) \\ &= \sum_i (y_i - \hat{\alpha} - \hat{\beta}x_i)y_i - \hat{\alpha} \sum_i (y_i - \hat{\alpha} - \hat{\beta}x_i) \\ &\quad - \hat{\beta} \sum_i (y_i - \hat{\alpha} - \hat{\beta}x_i)x_i = \sum_i (y_i - \hat{\alpha} - \hat{\beta}x_i)y_i \\ &= S_{yy} - (\hat{\alpha}S_y + \hat{\beta}S_{xy}) = SS_t - SS_r \end{aligned}$$

Como $\hat{\alpha}$ y $\hat{\beta}$ resuelven las ecuaciones normales, dos términos de la cuarta igualdad son iguales a cero.

10/04/2025 "Clase_3 - regresion multiple" III - 31/42

ya que

$$\begin{aligned} \sum_{k=1}^q n_k \bar{y}_k^2 + \sum_{k=1}^q \sum_{i_k=1}^{n_k} (y_{i_k} - \bar{y}_k)^2 &= \\ \sum_{k=1}^q n_k \bar{y}_k^2 + \sum_{k=1}^q \sum_{i_k=1}^{n_k} y_{i_k}^2 - 2 \sum_{k=1}^q \sum_{i_k=1}^{n_k} y_{i_k} \bar{y}_k + \sum_{k=1}^q \sum_{i_k=1}^{n_k} \bar{y}_k^2 &= \\ \sum_{k=1}^q n_k \bar{y}_k^2 + \sum_{i=1}^n y_i^2 - 2 \sum_{k=1}^q n_k \bar{y}_k \bar{y}_k + \sum_{k=1}^q n_k \bar{y}_k^2 &= \sum_{i=1}^n y_i^2 \end{aligned}$$

- SS_T La suma de cuadrados *total* se descompone en
- SS_B suma de cuadrados *between* debido al modelo, o sea a las diferencias entre clases, y
- SS_W suma de cuadrados *within* de desvío al modelo, debido a la variación dentro de las clases.

10/04/2025 "Clase_3 - regresion multiple" III - 30/42

Clase 3 Análisis de la varianza

Se consigue

$$SS_t = S_{yy} = (\hat{\alpha}S_y + \hat{\beta}S_{xy}) + \sum_i (y_i - \hat{\eta}_{x_i})^2 = SS_r + SS_e$$

con

- $SS_t = S_{yy}$, suma de cuadrados *total*, se descompone en
- $SS_r = S_{\hat{\eta}\hat{\eta}}$ suma de cuadrados de la *regresión*,
- SS_e suma de cuadrados del *error* o de los *residuos*.

10/04/2025 "Clase_3 - regresion multiple" III - 32/42

3. En el caso de la regresión múltiple, una vez estimados los $\hat{\beta}$ resulta que el cuadrado de la distancia entre \mathbf{y} y \mathbf{X} es

$$\begin{aligned}\mathbf{e}'\mathbf{e} &= (\mathbf{y} - \hat{\boldsymbol{\eta}})'(\mathbf{y} - \hat{\boldsymbol{\eta}}) = (\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}})'(\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}}) = \\ &= \mathbf{y}'\mathbf{y} - \mathbf{y}'\mathbf{X}\hat{\boldsymbol{\beta}} - \hat{\boldsymbol{\beta}}'\mathbf{X}'\mathbf{y} + \hat{\boldsymbol{\beta}}'\mathbf{X}'\mathbf{X}\hat{\boldsymbol{\beta}} = \\ &= \mathbf{y}'\mathbf{y} - \hat{\boldsymbol{\beta}}'\mathbf{X}'\mathbf{X}\hat{\boldsymbol{\beta}} = \mathbf{y}'\mathbf{y} - \hat{\boldsymbol{\eta}}'\hat{\boldsymbol{\eta}}\end{aligned}$$

pues, según las ecuaciones normales,

$$\mathbf{y}'\mathbf{X}\hat{\boldsymbol{\beta}} = (\hat{\boldsymbol{\beta}}'\mathbf{X}'\mathbf{y})' = \hat{\boldsymbol{\beta}}'\mathbf{X}'\mathbf{X}\hat{\boldsymbol{\beta}},$$

donde $\mathbf{y}'\mathbf{y} = \hat{\boldsymbol{\eta}}'\hat{\boldsymbol{\eta}} + \mathbf{e}'\mathbf{e} = \mathbf{y}'\mathcal{P}\mathbf{y} + \mathbf{y}'\mathcal{E}\mathbf{y}$.

10/04/2025

"Clase_3 - regresion multiple"

III - 33/42

Clase 3

Análisis de la varianza

Los elementos de esta partición se suelen representar en una *tabla de análisis de varianza* como

Fuente	Grados de libertad (DF)	Sumas de cuadrados (SS)	Cuadrados promedios (MS)
Between	q	SS_B	$MS_B = SS_B/q$
Within	$n - q$	SS_W	$MS_W = SS_W/(n - q)$
Total	n	SS_T	

Fuente	Grados de libertad (DF)	Sumas de cuadrados (SS)	Cuadrados promedios (MS)
Regresión	p	SS_r	$MS_r = SS_r/(p)$
Error	$n - p$	SS_e	$MS_e = SS_e/(n - p)$
Total	n	SS_t	

Estaremos viendo la utilidad de los cuadrados promedios.

10/04/2025

"Clase_3 - regresion multiple"

III - 35/42

Esto se puede escribir también

$$SS_t = SS_r + SS_e$$

Así se ha compartido la suma de cuadrados de las observaciones:

- una parte SS_r debido a la regresión de \mathbf{y} sobre \mathbf{X}
 - otra, SS_e , debido al error.
- Por tanto:
- $\hat{\boldsymbol{\eta}}$ contiene la información sobre el modelo $\boldsymbol{\eta} = \mathbf{X}\boldsymbol{\beta}$,
 - \mathbf{e} solo contiene la información sobre el error,
 - $\mathbf{e}'\mathbf{e}$ debe informar sobre la varianza del error.

10/04/2025

"Clase_3 - regresion multiple"


III - 34/42

Clase 3

Apalancamiento

Apalancamiento

El *apalancamiento* se mide con la diagonal de la matriz $\hat{\mathbf{H}}$.



10/04/2025

"Clase_3 - regresion multiple"

III - 36/42

- A la matriz $\mathcal{P} = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}' = \hat{\mathbf{H}}$, proyector sobre el espacio generado para \mathbf{X} (inclusivo del vector $\mathbf{1}$) se le llama también *hat matrix*.
- Su valor h_{ij} se lo interpreta como la influencia del valor y_j , debido a los valores \mathbf{x}_j correspondientes, sobre la predicción η_i .
- Al valor h_{ii} se lo llama *apalancamiento* y representa cuanto la i -ésima observación influye sobre la regresión. La verdad es que esto solo depende de la distancia de la observación del baricentro de los \mathbf{x}_j .
- Como el promedio de los h_{ii} es $(p)/n$, tien que mirar de cerca las observaciones con $h_{ii} \geq 2(p)/n$.

10/04/2025


"Clase_3 - regresion multiple"

III - 37/42

Clase 3

Apalancamiento

En los gráficos se comparan los valores estimados con los observados (izquierda) y los residuos (derecha). En rojo el modelo.



10/04/2025

"Clase_3 - regresion multiple"

III - 39/42

Ejemplo

El archivo *Linnerud* tiene mediciones físicas de 20 atletas de un gimnasio (*Peso*, *Cintura*, *Pulsaciones*) y tres prestaciones (*Tracciones*, *Flecciones*, *Saltos*). Intentamos de explicar las Tracciones a través de las mediciones físicas.

El modelo siendo: $\text{Pulls} \sim \text{Weight} + \text{Waist} + \text{Pulse}$
se resultan los $\hat{\beta}$:

(Intercept)	Weight	Waist	Pulse
47.96841291	0.07884384	-1.45584256	-0.01895002

y la siguiente tabla de análisis de la varianza:

	Degrees of Freedom	Sum of squares	Mean squares
Regression	4	1966.3455	491.58638
Residuals	16	350.6545	21.91591
Total	20	2317.0000	0.00000

10/04/2025

"Clase_3 - regresion multiple"

III - 38/42

Clase 3

Apalancamiento

Resultan con apalancamiento relevante ($> 2p/n = 0,4$) los atletas 9 y 14.

Corriendo el mismo modelo sin ellos, se resultan los $\hat{\beta}$:

(Intercept)	Weight	Waist	Pulse
61.23658732	0.14053819	-2.27498972	0.06383284

que se pueden comparar a los del modelo completo:

(Intercept)	Weight	Waist	Pulse
47.96841291	0.07884384	-1.45584256	-0.01895002


Las diferencias son bastante evidentes: en los gráficos se ven las diferencias entre valores estimados e residuos con respecto a los valores y observados.

10/04/2025

"Clase_3 - regresion multiple"

III - 40/42

En el gráfico se comparan valores observados (horizontal) con los estimados (vertical). En rojo las estimaciones sin 9 y 14.



Aquí los residuos (con signo cambiado) son representados contra los valores observados.

