

# EL MODELO LINEAL

## Clase 4

### Propiedades estadísticas

Sergio Camiz

LIMA - Marzo-Mayo 2025

---

20/04/2025 "Clase\_4 - Propiedades estadísticas" IV - 1/36

---

Clase 4 Propiedades estadísticas de los estimadores

### ***Propiedades estadísticas de los estimadores***

Para poder estudiar propiedades estadísticas de los estimadores, se necesitan unas hipótesis, que llevan a los resultados.

- Se consideran  $p$  vectores, incluyendo el vector  $\mathbf{x}_1 = (1, \dots, 1)'$ , de valores observados sobre  $n$  unidades fijadas (no al azar), formando la matriz de variables descriptivas  $\mathbf{X}$ .
- por cada unidad  $i$ , se observan valores  $y_i$ ,  $i = 1, \dots, n$  de la variable respuesta, que resulta una variable aleatoria.
- siempre se supone un error, así que resulta por cada  $i$

$$y_i = \sum_j \beta_j x_{ij} + \varepsilon_i = \eta_i + \varepsilon_i \quad (1)$$

con  $\varepsilon_i$  el desvío del valor observado al modelo, o sea,  $\varepsilon_i = y_i - \eta_i$  que es también una variable aleatoria.

---

20/04/2025 "Clase\_4 - Propiedades estadísticas" IV - 3/36

### Asuntos de la Clase 4

- Propiedades estadísticas de los estimadores
- Análisis de la varianza
- Inferencia
- El programa `lm`

---

20/04/2025 "Clase\_4 - Propiedades estadísticas" IV - 2/36

---

Clase 4 Propiedades estadísticas de los estimadores

Se necesitan otras hipótesis:

- Las observaciones  $y_i$  son variables aleatorias independientes.
- Por cada observación, o sea por cada vector  $\mathbf{x}_i$  (filas de  $\mathbf{X}$ ),  $y_i$  tiene la misma distribución, con
- $E(y_i|\mathbf{x}_i) = \eta_i$ , o sea el modelo es correcto;
- $V(y_i|\mathbf{x}_i) = \sigma^2$  constante, por cada  $i = 1, \dots, n$ .
- un error experimental siempre existe, dependiendo de la influencia sobre  $y$  de otros  $q$  factores  $\mathbf{x}_{j'}$  no incluídos, así el modelo (1) es un abreviado de

$$y_i = \sum_j \beta_j x_{ij} + \sum_{j'} \beta_{j'} x_{ij'}.$$

Si  $q$  es grande el teorema del límite central asegura la normalidad de  $\varepsilon_i$ .

---

20/04/2025 "Clase\_4 - Propiedades estadísticas" IV - 4/36

Estas condiciones se pueden sintetizar ecuivalentemente

$$\left\{ \begin{array}{l} y_i = \eta_i + \varepsilon_i \\ E(y_i|\mathbf{x}_i) = \eta_i \text{ (correcto)} \\ V(y_i|\mathbf{x}_i) = \sigma^2 \text{ (homoscedasticidad)} \\ y_i \text{ y } y_k \text{ independientes } \forall i \neq k \\ y_i \sim N(\eta_i, \sigma^2) \text{ (normalidad)} \end{array} \right\} \left\{ \begin{array}{l} y_i = \eta_i + \varepsilon_i \\ E(\varepsilon_i|\mathbf{x}_i) = 0 \\ V(\varepsilon_i|\mathbf{x}_i) = \sigma^2 \\ \varepsilon_i \text{ y } \varepsilon_k \text{ independientes } \forall i \neq k \\ \varepsilon_i \sim N(0, \sigma^2) \end{array} \right.$$

por cada  $i \in (1, n)$ , y en forma matricial

$$\left\{ \begin{array}{l} \mathbf{y} = \boldsymbol{\eta} + \boldsymbol{\varepsilon} \\ E(\mathbf{y}|\mathbf{X}) = \boldsymbol{\eta} \\ V(\mathbf{y}|\mathbf{X}) = \sigma^2 \mathbf{I} \\ y_i \text{ y } y_k \text{ independientes } \forall i \neq k \\ \mathbf{y} \sim N(\boldsymbol{\eta}, \sigma^2 \mathbf{I}) \end{array} \right\} \left\{ \begin{array}{l} \mathbf{y} = \boldsymbol{\eta} + \boldsymbol{\varepsilon} \\ E(\boldsymbol{\varepsilon}) = \mathbf{0} \\ V(\boldsymbol{\varepsilon}) = \sigma^2 \mathbf{I} \\ \varepsilon_i \text{ y } \varepsilon_k \text{ independientes } \forall i \neq k \\ \boldsymbol{\varepsilon} \sim N(\mathbf{0}, \sigma^2 \mathbf{I}) \end{array} \right.$$

20/04/2025 "Clase\_4 - Propiedades estadísticas" IV - 5/36

## Esperanza

Sabiendo que  $E(\mathbf{y}) = \boldsymbol{\eta} = \mathbf{X}\boldsymbol{\beta}$ , y que la matriz  $\mathbf{X}$  es fijada, se resulta que

$$\begin{aligned} E(\hat{\boldsymbol{\beta}}) &= E((\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}) = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'E(\mathbf{y}) = \\ &= (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\boldsymbol{\eta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{X}\boldsymbol{\beta} = \boldsymbol{\beta} \\ E(\hat{\boldsymbol{\eta}}) &= E(\mathbf{X}\hat{\boldsymbol{\beta}}) = \mathbf{X}E(\hat{\boldsymbol{\beta}}) = \mathbf{X}\boldsymbol{\beta} = \boldsymbol{\eta} \\ E(\mathbf{e}) &= E(\hat{\boldsymbol{\varepsilon}}) = E(\mathbf{y} - \hat{\boldsymbol{\eta}}) = E(\mathbf{y}) - E(\hat{\boldsymbol{\eta}}) = \boldsymbol{\eta} - \boldsymbol{\eta} = \mathbf{0} \end{aligned}$$

En seguida se utilizarán las relaciones siguientes. Para su prueba, verse por ejemplo Mood *et al.* (1974):

$$\begin{aligned} E(ax + b) &= aE(x) + b & V(ax + b) &= a^2V(x) \\ E(x \pm y) &= E(x) \pm E(y) & V(x \pm y) &= V(x) + V(y) \pm 2cov(x, y) \\ E(xy) &= E(x)E(y) + cov(x, y) & V(xy) &= V(x)V(y) + E(x)E(y) \\ E(x^2) &= (E(x))^2 + V(x) & V(x^2) &= (V(x))^2 + (E(x))^2 \end{aligned}$$

20/04/2025 "Clase\_4 - Propiedades estadísticas" IV - 6/36

## Varianza

Considerando también que  $V(\mathbf{y}) = \sigma^2 \mathbf{I}$ , resulta

$$\begin{aligned} V(\hat{\boldsymbol{\beta}}) &= V((\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}) = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'V(\mathbf{y})\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1} = \\ &= \sigma^2(\mathbf{X}'\mathbf{X})^{-1} \\ V(\hat{\boldsymbol{\eta}}) &= V(\mathbf{X}\hat{\boldsymbol{\beta}}) = \mathbf{X}V(\hat{\boldsymbol{\beta}})\mathbf{X}' = \sigma^2\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}' = \sigma^2\mathcal{P} \\ V(\mathbf{e}) &= V(\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}}) = V(\mathbf{y} - \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}) = \\ &= \sigma^2(\mathbf{I}_n - \mathcal{P}) = \sigma^2\mathcal{E} \end{aligned}$$

Hay que observar que los estimadores de los parámetros tienen una covarianza entre ellos, dependiendo de las relaciones lineales entre regresores.

## El teorema de Gauss-Markov

Dados

1.  $n$  conjuntos de observaciones, dispuestas en forma de matriz  $(\mathbf{X}, \mathbf{y})$ , con
2.  $\mathbf{X}$  matriz de valores previamente elegidos, y
3.  $\mathbf{y}$  valores al azar correspondientes y independientes para los cuales  $E(\mathbf{y}|\mathbf{X}) = \mathbf{X}\boldsymbol{\beta}$ ,  $V(\mathbf{y}|\mathbf{X}) = \sigma^2 I$ ;
4. Sea  $\hat{\boldsymbol{\beta}}$  la estimación de mínimos cuadrados de  $\boldsymbol{\beta}$ .
5.  $\boldsymbol{\tau} = \mathbf{a}'\boldsymbol{\beta}$ , con  $\mathbf{a}' = (a_1, \dots, a_n)$  un vector de constantes.

Bajo 1., ..., 5., entre todos los estimadores *insesgados* y *lineal* en  $\mathbf{y}$  de  $\boldsymbol{\tau}$ , el de mínimos cuadrados  $\hat{\boldsymbol{\tau}} = \mathbf{a}'\hat{\boldsymbol{\beta}}$  es de varianza mínima.

Por lo tanto, cada  $\hat{\beta}_j$  y  $\hat{\eta}_i$  entre todos los estimadores insesgados y lineales en  $\mathbf{y}$ , son los de varianza mínima.

---

20/04/2025 "Clase\_4 - Propiedades estadísticas" IV - 9/36

---

Clase 4 Propiedades estadísticas de los estimadores

La covarianza entre  $\mathbf{t}$  y  $\hat{\boldsymbol{\tau}}$  vale

$$\begin{aligned} \text{cov}(\hat{\boldsymbol{\tau}}, \mathbf{t}) &= \text{cov}(\mathbf{c}'\mathbf{y}, \mathbf{d}'\mathbf{y}) = E(\mathbf{d}'(\mathbf{y} - \boldsymbol{\eta})(\mathbf{y} - \boldsymbol{\eta})'\mathbf{c}) = \sigma^2 \mathbf{d}'\mathbf{c} = \\ &= \sigma^2 \mathbf{d}'\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{a} = \sigma^2 \mathbf{a}'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{a} = V(\hat{\boldsymbol{\tau}}) \end{aligned}$$

Se encuentra entonces que

$$0 \leq V(\mathbf{t} - \hat{\boldsymbol{\tau}}) = V(\mathbf{t}) + V(\hat{\boldsymbol{\tau}}) - 2 \text{cov}(\mathbf{t}, \hat{\boldsymbol{\tau}}) = V(\mathbf{t}) - V(\hat{\boldsymbol{\tau}})$$

y por tanto  $V(\mathbf{t}) \geq V(\hat{\boldsymbol{\tau}})$ .

---

20/04/2025 "Clase\_4 - Propiedades estadísticas" IV - 11/36

*Prueba.*

Es evidente que  $E(\hat{\boldsymbol{\tau}}) = \boldsymbol{\tau}$  y que  $\hat{\boldsymbol{\tau}}$  es lineal en  $\mathbf{y}$  pues

$$\hat{\boldsymbol{\tau}} = \mathbf{a}'\hat{\boldsymbol{\beta}} = \mathbf{a}'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y} = \mathbf{c}'\mathbf{y},$$

entonces su varianza es

$$V(\hat{\boldsymbol{\tau}}) = V(\mathbf{a}'\hat{\boldsymbol{\beta}}) = \sigma^2 \mathbf{a}'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{a}.$$

Supongamos exista otra estimación de  $\boldsymbol{\tau}$ , insesgada y lineal en  $\mathbf{y}$ , digamos  $\mathbf{t} = \mathbf{d}'\mathbf{y}$ , con  $\mathbf{d} \neq \mathbf{c}$ . Por la condición de insesgamiento,  $E(\mathbf{t}|\mathbf{X}) = \boldsymbol{\tau}$  y por lo tanto

$$E(\mathbf{t}) = \mathbf{d}'E(\mathbf{y}|\mathbf{X}) = \mathbf{d}'\mathbf{X}\boldsymbol{\beta} = \boldsymbol{\tau} = \mathbf{a}'\boldsymbol{\beta}$$

por cada  $\boldsymbol{\beta}$ . Por tanto  $\mathbf{d}'\mathbf{X} = \mathbf{a}'$ .

---

20/04/2025 "Clase\_4 - Propiedades estadísticas" IV - 10/36

---

Clase 4 Propiedades estadísticas de los estimadores

## Análisis de varianza del modelo

Una vez estimados los  $\hat{\boldsymbol{\beta}}$  resulta que el cuadrado de la distancia entre  $\mathbf{y}$  y  $\mathbf{X}$  es

$$\begin{aligned} \mathbf{e}'\mathbf{e} &= (\mathbf{y} - \hat{\boldsymbol{\eta}})'(\mathbf{y} - \hat{\boldsymbol{\eta}}) = (\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}})'(\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}}) = \\ &= \mathbf{y}'\mathbf{y} - \mathbf{y}'\mathbf{X}\hat{\boldsymbol{\beta}} - \hat{\boldsymbol{\beta}}'\mathbf{X}'\mathbf{y} + \hat{\boldsymbol{\beta}}'\mathbf{X}'\mathbf{X}\hat{\boldsymbol{\beta}} = \\ &= \mathbf{y}'\mathbf{y} - \hat{\boldsymbol{\beta}}'\mathbf{X}'\mathbf{X}\hat{\boldsymbol{\beta}} = \mathbf{y}'\mathbf{y} - \hat{\boldsymbol{\eta}}'\hat{\boldsymbol{\eta}} \end{aligned}$$

pues, según las ecuaciones normales,

$$\mathbf{y}'\mathbf{X}\hat{\boldsymbol{\beta}} = (\hat{\boldsymbol{\beta}}'\mathbf{X}'\mathbf{y})' = \hat{\boldsymbol{\beta}}'\mathbf{X}'\mathbf{X}\hat{\boldsymbol{\beta}},$$

de donde  $\mathbf{y}'\mathbf{y} = \hat{\boldsymbol{\eta}}'\hat{\boldsymbol{\eta}} + \mathbf{e}'\mathbf{e} = \mathbf{y}'\mathcal{P}\mathbf{y} + \mathbf{y}'\mathcal{E}\mathbf{y}$ .

Esto resulta también del teorema de Pitágoras.

---

20/04/2025 "Clase\_4 - Propiedades estadísticas" IV - 12/36

Se puede escribir también

$$SS_t = SS_r + SS_e,$$

ya que se ha compartido la suma de cuadrados de las observaciones:

- una parte  $SS_r$  debido a la regresión de  $\mathbf{y}$  sobre  $X$
- la otra,  $SS_e$ , debido al error.

Por tanto:

- $\hat{\boldsymbol{\eta}}$  contiene la información sobre el modelo  $\boldsymbol{\eta} = X\boldsymbol{\beta}$ ,
- $\mathbf{e}$  solo contiene la información sobre el error,
- $\mathbf{e}'\mathbf{e}$  solo debe informar sobre  $\sigma^2$ .

Se suele enriquecer la tabla de análisis de varianza con las esperanzas como sigue:

Fuente	Grados de libertad (DF)	Sumas de cuadrados (SS)	Cuadrados promedios (MS)	Esperanza de los cuadrados promedios $E(MS)$
Regresión	$p$	$SS_r$	$MS_r = SS_r/p$	$\sigma^2 + \boldsymbol{\beta}'\mathbf{X}'\mathbf{X}\boldsymbol{\beta}/p = \sigma^2 + \boldsymbol{\eta}'\boldsymbol{\eta}/p$
Error	$n - p$	$SS_e$	$MS_e = SS_e/(n - p)$	$\sigma^2$
Total	$n$	$SS_t$		

Los grados de libertad corresponden a las dimensiones de los espacios:

- el espacio de los estimadores  $X$  tiene  $p$  dimensiones,
- el espacio de los residuos tiene dimensión  $n - p$ .

Nótese que las esperanzas de los cuadrados promedios son diferentes solo si  $\|\boldsymbol{\eta}\| \neq 0$ .

Calculemos ahora las esperanzas  $SS_r$  y  $SS_e$ :

$$E(SS_r) = E(\mathbf{y}'\mathcal{P}\mathbf{y}) = \boldsymbol{\beta}'\mathbf{X}'\mathcal{P}\mathbf{X}\boldsymbol{\beta} + \text{tr}(\mathcal{P}\sigma^2\mathbf{I}) = \boldsymbol{\beta}'\mathbf{X}'\mathbf{X}\boldsymbol{\beta} + p\sigma^2$$

$$E(SS_e) = E(\mathbf{y}'\mathcal{E}\mathbf{y}) = \boldsymbol{\beta}'\mathbf{X}'\mathcal{E}\mathbf{X}\boldsymbol{\beta} + \text{tr}(\mathcal{E}\sigma^2\mathbf{I}) = (n - p)\sigma^2$$

resultando el producto  $\mathcal{E}\mathbf{X} = 0$ . Por lo tanto los cuadrados promedios se resultan

$$MS_r = SS_r/p \quad E(MS_r) = \boldsymbol{\beta}'\mathbf{X}'\mathbf{X}\boldsymbol{\beta}/p + \sigma^2$$

$$MS_e = SS_e/(n - p) \quad E(MS_e) = \sigma^2$$

así que  $MS_e$  es un estimador insesgado de  $\sigma^2$ .

## Inferencia

Para hacer inferencia a una población, y también evaluar si el modelo resulta fiable y es necesario imponer hipótesis sobre la distribución de  $\mathbf{y}$  condicionada a los  $\mathbf{X}$ .

Si se asume la distribución de los  $y_i|\mathbf{x}_i$  multinormal, o sea normal por cada valor de los  $x_{ij}$ , en seguida se consiguen las distribuciones de los resultados.

Sino hay que conocer resultados parecidos por la distribución que resulta o se hace recurso a métodos de remuestreo (Manly, 2007), construyendo distribuciones empíricas.

Se presentan aquí los resultados más importantes relativos a las muestras de una distribución normal multivariada, que servirán a los test estadísticos. Para una lectura más detallada, demostraciones y referencias se puede ver Guttman (1982: pp. 62-95).

## Distribuciones estadísticas

**Definición.** Se dice que el vector aleatorio  $\mathbf{y} \in \mathbb{R}^n$ , tiene una distribución *multi-normal* si su función de densidad  $d(\mathbf{y})$  es

$$d(\mathbf{y}) = \frac{1}{\sqrt{(2\pi)^n |\Sigma|}} e^{-\frac{1}{2}(\mathbf{y}-\boldsymbol{\mu})'\Sigma^{-1}(\mathbf{y}-\boldsymbol{\mu})}$$

donde la matriz de varianza/covarianza  $\Sigma$  es simétrica definida positiva, con  $|\Sigma| = \Pi_i \lambda_i$  producto de su autovalores, y el vector de promedios  $\boldsymbol{\mu}$  tiene componentes finitas. Entonces se escribe  $\mathbf{y} \sim N(\boldsymbol{\mu}, \Sigma)$ , con  $E(\mathbf{y}) = \boldsymbol{\mu}$  y  $V(\mathbf{y}) = \Sigma$ .

**Teorema.** Si  $\mathbf{y} \sim N(\boldsymbol{\mu}, \Sigma)$  y  $\Sigma$  es diagonal, las componentes  $y_i$  de  $\mathbf{y}$  son estadísticamente independientes.

Donde la necesidad de normalidad y independencia de los  $y_i$ .

---

20/04/2025 "Clase\_4 - Propiedades estadísticas" IV - 17/36

---

Clase 4 Inferencia

Como consecuencia de la multinormalidad, se determinan las distribuciones de formas cuadráticas, o sea las sumas de cuadrados, que resultan en general:

**Teorema.** Sea un vector aleatorio  $\mathbf{y} \sim N(\boldsymbol{\mu}, \sigma^2 \mathbf{I})$ , con  $\Sigma = \mathbf{P}'\mathbf{P}$  y  $Q$  la forma cuadrática centrada

$$Q = (\mathbf{y} - \boldsymbol{\mu})'\mathbf{G}(\mathbf{y} - \boldsymbol{\mu})$$

con  $\mathbf{G}$  simétrica y real. Entonces la ley de distribución de  $Q$  es una combinación lineal de  $n$  variables aleatorias independientes de ley chi-cuadrado con 1 grado de libertad

$$Q \sim \sum_i \lambda_i \chi_{1,i}^2$$

donde los  $\lambda_i$  son los autovalores de  $\mathbf{P}'\mathbf{G}\mathbf{P}$  (y de  $\Sigma\mathbf{G}$  y  $\mathbf{G}\Sigma$ ).

---

20/04/2025 "Clase\_4 - Propiedades estadísticas" IV - 19/36

Si asumimos normal independiente la distribución de los residuos  $\boldsymbol{\varepsilon} \sim N(\mathbf{0}, \Sigma)$  se resulta la distribución

$$\mathbf{y} \sim N(\mathbf{X}\boldsymbol{\beta}, \Sigma),$$

donde la función de verosimilitud

$$L(\boldsymbol{\beta}, \sigma^2) = \frac{1}{\sqrt{(2\pi)^n \sigma^2}} e^{-\frac{1}{2\sigma^2}(\mathbf{y}-\mathbf{X}\boldsymbol{\beta})'(\mathbf{y}-\mathbf{X}\boldsymbol{\beta})}.$$

Entonces el estimador de máxima verosimilitud de  $\boldsymbol{\beta}$  tiene que maximizar la log-verosimilitud

$$l(\boldsymbol{\beta}, \sigma^2) = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\sigma^2) - \frac{1}{2\sigma^2}(\mathbf{y} - \mathbf{X}\boldsymbol{\beta})'(\mathbf{y} - \mathbf{X}\boldsymbol{\beta})$$

y resulta ser  $\hat{\boldsymbol{\beta}}$ , que por lo tanto es de mínima varianza.

---

20/04/2025 "Clase\_4 - Propiedades estadísticas" IV - 18/36

---

Clase 4 Inferencia

Por consecuencia, si  $\lambda_i = 1$  o  $0$  se deduce:

**Teorema.** Una condición necesaria y suficiente por que  $Q$  tenga una ley de distribución de chi-cuadrado con  $p < n$  grados de libertad es que  $\mathbf{P}'\mathbf{G}\mathbf{P}$  sea idempotente y de rango  $p$ . Si  $\Sigma = \sigma^2 \mathbf{I}$  la condición deviene en que  $\mathbf{G}$  sea idempotente de rango  $p$ .

**Teorema** (Craig). Sea un vector aleatorio  $\mathbf{y} = N(\boldsymbol{\mu}, \Sigma)$  y las dos formas cuadráticas

$$Q_i = (\mathbf{y} - \boldsymbol{\mu})'\mathbf{G}_i(\mathbf{y} - \boldsymbol{\mu}), i = 1, 2$$

con  $\mathbf{G}_i$  reales y simétricas. Entonces  $Q_1$  y  $Q_2$  son estadísticamente independientes si y solo si  $\mathbf{G}_1 \Sigma \mathbf{G}_2 = \mathbf{0}$ .

Esto es relevante para los proyectores ortogonales entre si.

---

20/04/2025 "Clase\_4 - Propiedades estadísticas" IV - 20/36

**Teorema.** (Cochran). Sea  $y \sim N(0, 1)$  una variable aleatoria y sean  $n$  observaciones de  $y$  independientes, formando un vector aleatorio  $\mathbf{y} \sim N(\mathbf{0}, \mathbf{I})$ . Sea por otro lado

$$Q = \mathbf{y}'\mathbf{y} = Q_1 + Q_2 + \dots + Q_k$$

donde  $Q_i = \mathbf{y}'\mathbf{A}_i\mathbf{y}$  es una forma cuadrática de rango  $rg(\mathbf{A}_i) = n_i$ , y  $\mathbf{A}_i$  es una matriz simétrica  $n \times n, i = 1, \dots, k$ . Entonces las siguientes condiciones son equivalentes:

- $Q_1, Q_2, \dots, Q_k$  son estadísticamente independientes;
- $Q_1, Q_2, \dots, Q_k$  tienen individualmente distribuciones de chi-cuadrado, con  $n_1, \dots, n_k$  grados de libertad;
- $n_1 + n_2 + \dots + n_k = n$ .

Esto nos sirve para la partición de  $SS_y$ .

---

20/04/2025 "Clase\_4 - Propiedades estadísticas" IV - 21/36

---

Clase 4 Inferencia

### Test del modelo

Se supone que el vector  $\mathbf{y}$  tiene

- en cada punto de observación una distribución normal centrada sobre su esperanza  $\boldsymbol{\eta}$
- y de varianza constante,  $\mathbf{y} \sim N(\boldsymbol{\eta}, \sigma^2 \mathbf{I})$ .
- Bajo la hipótesis nula  $H_0 : \boldsymbol{\beta} = \mathbf{0}$  se tiene
- $E(\mathbf{y}) = \mathbf{0}$
- y por tanto  $\mathbf{y} = N(\mathbf{0}, \sigma^2 \mathbf{I})$ .
- Por el teorema de Craig,  $SS_r$  y  $SS_e$  son formas cuadráticas de una distribución normal estandarizada estadísticamente independientes, de matrices  $\mathcal{P}$  y  $\mathcal{E}$  tales que  $\sigma^2 \mathcal{P}\mathcal{E} = 0$ .

En consecuencia (teorema de Cochran, con  $k = 2$ ) se resulta

$$SS_r = \sigma^2 \chi_p^2 \text{ y } SS_e = \sigma^2 \chi_{n-p}^2.$$

---

20/04/2025 "Clase\_4 - Propiedades estadísticas" IV - 23/36

**Teorema.** Sea el vector aleatorio  $\mathbf{y} \sim N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$  y considere su distribución condicional

$$\mathbf{A}(\mathbf{y} - \boldsymbol{\mu}) = 0$$

donde  $\mathbf{A}$  es una matriz  $p \times n, p < n, \text{rk}(\mathbf{A}) = p$ . Entonces la distribución condicional de  $\mathbf{y}$  es tal que

$$Q = (\mathbf{y} - \boldsymbol{\mu})'\boldsymbol{\Sigma}^{-1}(\mathbf{y} - \boldsymbol{\mu}) = \chi_{n-p}^2$$

En fin, esto no sirve para  $SS_e$ .

---

20/04/2025 "Clase\_4 - Propiedades estadísticas" IV - 22/36

---

Clase 4 Inferencia

Se puede estimar  $\sigma^2$  también con el máximo de verosimilitud. Derivando  $l(\boldsymbol{\beta}, \sigma^2)$  por respecto a  $\sigma^2$  y igualando a cero

$$\frac{\partial l(\boldsymbol{\beta}, \sigma^2)}{\partial \sigma^2} = -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4}(\mathbf{y} - \mathbf{X}\boldsymbol{\beta})'(\mathbf{y} - \mathbf{X}\boldsymbol{\beta}) = 0,$$

se consigue, sustituyendo  $\hat{\boldsymbol{\beta}}$  a  $\boldsymbol{\beta}$ ,

$$-\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4}(\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}})'(\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}}) = -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4}\mathbf{e}'\mathbf{e} = 0,$$

donde

$$\frac{n}{2\sigma^2} = \frac{1}{2\sigma^4}\mathbf{e}'\mathbf{e} \text{ y } \sigma_{ml}^2 = \frac{\mathbf{e}'\mathbf{e}}{n},$$

de varianza mínima, pero sesgado, ya que  $E(MS_e) = E(SS_e/(n-p)) = \sigma^2$ . Se corrige con  $\sigma^2 = n/(n-p)\sigma_{ml}^2$ .

---

20/04/2025 "Clase\_4 - Propiedades estadísticas" IV - 24/36

Como resulta

$$SS_r = \sigma^2 \chi_p^2 \quad \text{y} \quad SS_e = \sigma^2 \chi_{n-p}^2$$

con las leyes  $\chi^2$  independientes, donde

$$\text{bajo } H_0 : \boldsymbol{\beta} = \mathbf{0}, \quad F = \frac{MS_r}{MS_e} = F_{p, n-p}$$

una  $F$  de Fisher con  $p$  y  $n-p$  grados de libertad. Por tanto, fijado un nivel de probabilidad  $\pi$  el test resulta ser

$$\begin{cases} \text{no aceptar } H_0 : \boldsymbol{\beta} = \mathbf{0}, & \text{si } \frac{MS_r}{MS_e} > F_{p, n-p; \pi} \\ \text{aceptar en otro caso.} \end{cases}$$

20/04/2025 "Clase\_4 - Propiedades estadísticas" IV - 25/36

Clase 4 Inferencia

Estas estadísticas permiten de enriquecer la tabla de análisis de la varianza con nuevas columnas.

Fuente	Grados de libertad (DF)	Sumas de cuadrados (SS)	Cuadrados promedios (MS)	Esperanza de los cuadrados promedios $E(MS)$	$F$	Prob
Regresión	$p$	$SS_r$	$MS_r = SS_r/p$	$\sigma^2 + \boldsymbol{\eta}'\boldsymbol{\eta}/p$	$\frac{MS_r}{MS_e}$	$\pi$
Error	$n-p$	$SS_e$	$MS_e = SS_e/(n-p)$	$\sigma^2$		
Total	$n$	$SS_t$				

De esta manera, toda la información para evaluar el modelo se encuentra en esta tabla. El valor  $\pi$  es la probabilidad asociada al valor de la  $F$  calculada, con  $p$  y  $n-p$  grados de libertad.

Como la hipótesis nula es  $\boldsymbol{\beta} = \mathbf{0}$ , si entonces  $\pi$  es más grande del nivel de aceptación que hemos establecido (por ejemplo  $5\% = 0,05$ ) podemos aceptar que no hay regresión, sino se puede rechazar, en el sentido que hay a lo menos un coeficiente  $\beta$  diferente de cero, y portanto el modelo tiene un sentido.

20/04/2025 "Clase\_4 - Propiedades estadísticas" IV - 27/36

Por otro lado, es fácil de ver que en la descomposición

$$(\mathbf{y} - \mathbf{X}\boldsymbol{\beta})'(\mathbf{y} - \mathbf{X}\boldsymbol{\beta}) = (\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}})'(\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}}) + (\hat{\boldsymbol{\beta}} - \boldsymbol{\beta})' \mathbf{X}' \mathbf{X} (\hat{\boldsymbol{\beta}} - \boldsymbol{\beta})$$

el primero término a la derecha vale  $\mathbf{e}'\mathbf{e}$  y se puede escribir

$$\begin{aligned} \frac{1}{\sigma^2}(\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}})'(\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}}) &= \frac{1}{\sigma^2}(\mathbf{y} - \mathbf{X}\boldsymbol{\beta})' \mathcal{E}(\mathbf{y} - \mathbf{X}\boldsymbol{\beta}), \\ \frac{1}{\sigma^2}(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta})' \mathbf{X}' \mathbf{X} (\hat{\boldsymbol{\beta}} - \boldsymbol{\beta}) &= \frac{1}{\sigma^2}(\mathbf{y} - \mathbf{X}\boldsymbol{\beta})' \mathcal{P}(\mathbf{y} - \mathbf{X}\boldsymbol{\beta}), \end{aligned}$$

dos formas cuadráticas independientes. Entonces resulta

$$\frac{(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta})' \mathbf{X}' \mathbf{X} (\hat{\boldsymbol{\beta}} - \boldsymbol{\beta})/p}{\mathbf{e}'\mathbf{e}/(n-p)} = \frac{\sigma^2 \chi_p^2/p}{\sigma^2 \chi_{n-p}^2/(n-p)} = F_{p, n-p}$$

donde se construye la región de confianza de  $\boldsymbol{\beta}$  al nivel de  $1 - \pi$ .

$$C_{1-\pi} = \left\{ \boldsymbol{\beta} \mid (\boldsymbol{\beta} - \hat{\boldsymbol{\beta}})' \mathbf{X}' \mathbf{X} (\boldsymbol{\beta} - \hat{\boldsymbol{\beta}}) \leq p MS_e F_{p, n-p; \pi} \right\}$$

20/04/2025 "Clase\_4 - Propiedades estadísticas" IV - 26/36

Clase 4 Inferencia

### Test de los $\hat{\beta}_i$

Si el test *ANOVA* es positivo, o sea el modelo tiene sentido, entonces se pueden testar los  $\hat{\beta}_i$ . Como  $\hat{\boldsymbol{\beta}}$  es distribuido multinormalmente con promedio  $\boldsymbol{\beta}$  y varianza  $\sigma^2(\mathbf{X}'\mathbf{X})^{-1}$ , cada  $\hat{\beta}_i$  tiene una distribución normal  $\hat{\beta}_i = N(\beta_i, \sigma^2 c_{ii})$  con  $c_{ii}$  elemento diagonal de  $(\mathbf{X}'\mathbf{X})^{-1}$ . Como su *desvío estándar* es  $SD(\hat{\beta}_i) = \sqrt{MS_e c_{ii}}$ , el test resulta

$$\begin{cases} \text{no aceptar } H_0 : \hat{\beta}_i = \beta_i, & \text{si } \left| \frac{\hat{\beta}_i - \beta_i}{SD(\hat{\beta}_i)} \right| > t_{n-k; \pi/2} \\ \text{aceptar en otro caso.} \end{cases}$$

con intervalo de confianza (con cuidado)

$$C_{1-\pi} = \left\{ \beta_i \mid \hat{\beta}_i - SD(\hat{\beta}_i) t_{n-k; \pi/2} \leq \beta_i \leq \hat{\beta}_i + SD(\hat{\beta}_i) t_{n-k; \pi/2} \right\}$$

20/04/2025 "Clase\_4 - Propiedades estadísticas" IV - 28/36

**Test de la varianza  $SS_e$** 

La varianza del modelo  $\sigma^2$  es estimada para  $SS_e$ . Por lo tanto, siendo un chi-cuadrado, su intervalo de confianza es dado por

$$C_{1-\pi} = \left\{ \sigma^2 \left| \frac{SS_e}{\chi^2_{n-k;\pi/2}} \leq \sigma^2 \leq \frac{SS_e}{\chi^2_{n-k;1-\pi/2}} \right. \right\}$$

---

20/04/2025 "Clase\_4 - Propiedades estadísticas" IV - 29/36

---

Clase 4 Inferencia

---

**Test del predictor**

De manera análoga se calcula el desvío estándar del predictor  $\tilde{y}_0$ , correspondiente a un nuevo vector  $\mathbf{x}_0$  que se encuentre dentro de la región ocupada para los  $\mathbf{x}_{ik}$ . Esto vale

$$SD(\tilde{y}_0) = \sqrt{MS_e (1 + \mathbf{x}'_0 (\mathbf{X}'\mathbf{X})^{-1} \mathbf{x}_0)},$$

y por lo tanto su intervalo de confianza resulta ser

$$\{y | \tilde{y}_0 - SD(\tilde{y}_0) t_{n-p;\pi/2} \leq y \leq \tilde{y}_0 + SD(\tilde{y}_0) t_{n-p;\pi/2}\}$$

Nótese que este intervalo es más grande de lo de los  $\eta_i$ , ya que estos son estimaciones del promedio de los  $y_i$  correspondientes, mientras aquí es una observación. Entonces la varianza del predictor es la varianza del promedio más la varianza  $\sigma^2$  alrededor de esto.

---

20/04/2025 "Clase\_4 - Propiedades estadísticas" IV - 31/36

**Test de los  $\hat{\eta}_i$** 

Resulta

$$V(\hat{\boldsymbol{\eta}}) = V(\mathbf{X}\hat{\boldsymbol{\beta}}) = \mathbf{X}V(\hat{\boldsymbol{\beta}})\mathbf{X}' = \sigma^2 \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}',$$

entonces por la estimación de  $\hat{\eta}_i = \mathbf{x}'_i \hat{\boldsymbol{\beta}}$ , resulta su desvío estándar

$$SD(\hat{\eta}_i) = \sqrt{MS_e \mathbf{x}'_i (\mathbf{X}'\mathbf{X})^{-1} \mathbf{x}_i}$$

se deriva la condición del test

$$\left| \frac{\hat{\eta}_i - \eta_i}{SD(\hat{\eta}_i)} \right| > t_{n-p;\pi/2}$$

con intervalo de confianza

$$\left\{ \eta | \hat{\eta}_i - SD(\hat{\eta}_i) t_{n-p;\pi/2} \leq \eta \leq \hat{\eta}_i + SD(\hat{\eta}_i) t_{n-p;\pi/2} \right\}$$

---

20/04/2025 "Clase\_4 - Propiedades estadísticas" IV - 30/36

---

Clase 4 El programa **lm**

---

**El programa **lm****

El programa **lm** es el método básico para correr el modelo lineal en  $R$ . El comando es:

**LM = lm(MODELO, data=DATOS)**

con:

- **LM** la lista donde guardar los resultados,
- **DATOS** el archivo donde se encuentran tanto  $\mathbf{X}$  como  $\mathbf{y}$ ,
- **MODELO** es la descripción del modelo indicada con las reglas siguientes.

Los resultados principales se resultan con el comando:

**summary(LM)**

---

20/04/2025 "Clase\_4 - Propiedades estadísticas" IV - 32/36



## El modelo

- Un modelo se escribe usando una fórmula del tipo *variable de respuesta*  $\sim$  *variables predictoras*.
- La tilde se lee  $\sim$  como “se modela como una función de”.
- Básicamente se emplea el símbolo  $\sim$  entre un objeto, p.e.  $Y$ , a la izquierda y otros a la derecha, p.e.  $X$ , así indicando que se quiere modelar  $\mathbf{Y}$  con  $\mathbf{X}$ , es decir  $Y \sim X$  significa estimar el modelo  $y_i = \alpha + \beta x_i + \varepsilon_i$ .
- Si se quieren ajuntar otras variables se incluyen interponiendo el símbolo  $+$ : así  $Y \sim X + Z + T$  significa estimar el modelo  $y_i = \alpha + \beta x_i + \gamma z_i + \delta t_i + \varepsilon_i$ .

20/04/2025 "Clase\_4 - Propiedades estadísticas" IV - 33/36

Clase 4 El programa `lm`

- Si se quiere tener variables y interacciones, se puede escribir también  $Y \sim X * Z$ , igual a  $Y \sim X + Z + X : Z$ .
- Con tres variables  $Y \sim X * Z * T$  se indican todas las interacciones posibles, es decir:  
 $Y \sim X + Z + T + X : Z + X : T + Z : T + X : Z : T$ .
- El símbolo  $\wedge$  sirve para indicar las interacciones que se requieren: Si solo se requieren las interacciones hasta el segundo orden. Así  $Y \sim (X + Z + T)^2$  indica el modelo  $Y \sim X + Z + T + X : Z + X : T + Z : T$  sin la interacción triple.
- El grupo `%in%` sirve para indicar que los términos a su izquierda están juntados con los a la derecha. Así  $Y \sim X + Z + T \%in\% T$  se transforma en  $Y \sim X : T + Z : T + T$ .

20/04/2025 "Clase\_4 - Propiedades estadísticas" IV - 35/36

- Si se quieren ajuntar todas las variables contenidas en la matriz indicada en el parámetro `data=`, se escribe brevemente:  $Y \sim .$ , el punto indicando todas.
- El símbolo  $-$  se usa para tirar una variable del conjunto. Así  $Y \sim . - T$  indica el modelo con todas las variables en `data` menos la  $T$ .
- Así, escribiendo  $Y \sim X - 1$  se indica de estimar el modelo sin intercepta, es decir  $y_i = \beta x_i + \varepsilon_i$ , sin  $\alpha$ .
- Se emplea el símbolo  $:$  para indicar interacciones entre variables: así con  $Y \sim X + Z + X : Z$  significa estimar el modelo  $y_i = \alpha + \beta x_i + \gamma z_i + \delta x_i z_i + \varepsilon_i$

20/04/2025 "Clase\_4 - Propiedades estadísticas" IV - 34/36

Clase 4 El programa `lm`

- Cualquier fórmula incluyendo nombres de funciones es aceptada: así son aceptados  $Y \sim \log(Z) + \cos(T)$ .
- Si se puede tener confusión, la expresión matemática se incluye entre  $I()$ . Así es diferente  $Y \sim X + Z$  de  $Y \sim I(X + Z)$  ya que se modelan respectivamente  $y_i = \alpha + \beta x_i + \gamma z_i + \varepsilon_i$  y  $y_i = \alpha + \beta(x_i + z_i) + \varepsilon_i$ .

Los siguientes modelos son iguales, aún con fórmulas diferentes:

$Y \sim X + Z + W + X : Z + X : W + Z : W$

$Y \sim X * Z * W - X : Z : W$

$Y \sim (X + Z + W)^2$

todas corresponde al mismo modelo:

$Y_i = \beta_0 + \beta_1 X_i + \beta_2 Z_i + \beta_3 W_i + \beta_4 X_i Z_i + \beta_5 X_i W_i + \beta_6 Z_i W_i + \varepsilon_i$ .

20/04/2025 "Clase\_4 - Propiedades estadísticas" IV - 36/36